

Bilan correctifs predictif CDM2026

Test isole en sandbox — prod inchangee

Verite marche : Pinnacle de-margine Buchdahl (live_fresh)
Echantillon : 40 matchs CDM2026 avec cotes Pinnacle

Diagnostic en une ligne

V0 (prod) sous-estime le favori de 0.42 pts en moyenne, erreur absolue moyenne 3.45 pts, log-loss 0.9371.

Variants testes

V0 — production telle quelle
V1 — flip FAV_BOOST_GROUP -2.446 -> +2.446
V2 — abaisse seuil 380 -> 200 (tue zone morte)
V4 — sigmoid V6 pure (sans aucun boost V8)

Plan du rapport

V6 — V5 + quality term = 0 (sensibilite)

1. Tableau de synthese par variant (bias, MAE, log-loss)
2. Bias par tranche d'ecart Elo (la zone morte 200-380)
3. Top 15 matchs les plus sous-estimes (V0 vs marche)
4. Effet du cap lambda 4.0 sur les gros mismatches
5. Detail match par match (variant gagnant + recommandations)
6. Recommandation finale + plan de bascule

1. Synthèse par variant (vs marche Pinnacle)

Variant	n	Bias p_fav (pp)	MAE p_fav (pp)	Mediane bias (pp)	Log-loss
V0_prod	40	-0.42	3.45	-0.10	0.9371
V1_flip_fav	40	+0.18	3.70	+0.31	0.9378
V2_no_deadzone	40	-1.00	3.40	-0.89	0.9367
V4_v6_pure	40	+0.63	3.24	+0.72	0.9383
V5_v1_plus_v2	40	+1.22	4.34	+2.35	0.9391
V6_v5_quality0	40	+1.21	4.34	+2.33	0.9391


Lecture

- * bias positif = sur-estime le favori, bias negatif = sous-estime.
- * MAE = ecart absolu moyen entre proba modele et proba Pinnacle.
- * Log-loss croisee : modele vs distribution implied Pinnacle.
- * Le marche Pinnacle est utilise comme verite sharp (industrie).
C'est un proxy de qualite (margin ~2.5%) mais pas la realite finale : seul un backtest hors-CDM avec resultats observes peut prouver definitivement la generalisation des corrections.

Codes couleur :

- vert : bias > 0 (modele sur le favori)
- jaune : bias proche de zero (bonne calibration)
- rouge : bias < -1 pp (sous-estimation persistante)

2. Bias modele - marche par tranche d'ecart Elo



3. Top 15 matchs ou V0 sous-estime le plus le favori

Match	ΔElo	Pin p_fav	V0 p_fav	V5 p_fav	Bias V0	Bias V5
GHA-PAN	+4	49.6%	36.2%	36.2%	-13.39	-13.39
ENG-CRO	+90	53.9%	44.0%	44.0%	-9.86	-9.86
BEL-IRN	+226	66.7%	59.4%	61.8%	-7.39	-4.94
USA-PAR	+64	47.6%	41.7%	41.7%	-5.85	-5.85
USA-AUS	+134	54.5%	49.2%	49.2%	-5.30	-5.30
GER-CIV	+198	60.1%	54.9%	54.9%	-5.25	-5.25
POR-UZB	+383	77.4%	72.4%	76.4%	-4.96	-1.00
NZL-EGY	-146	54.8%	50.3%	50.3%	-4.48	-4.48
MEX-KOR	+131	53.4%	48.9%	48.9%	-4.46	-4.46
SWE-TUN	+110	50.0%	47.0%	47.0%	-2.99	-2.99
FRA-SEN	+267	65.6%	63.1%	65.6%	-2.44	+0.01
SCO-MAR	-73	44.7%	42.6%	42.6%	-2.12	-2.12
HAI-SCO	-280	66.2%	64.4%	66.9%	-1.74	+0.71
ECU-CUW	+400	75.6%	74.0%	77.9%	-1.64	+2.33
NOR-SEN	+100	47.5%	46.1%	46.1%	-1.42	-1.42

4. Effet cap lambda 4.0 (gros mismatches)

Aucun match WC2026 $|\Delta\text{Elo}| > 600$ dans l'échantillon Pinnacle
(les vrais mismatches sont aux MD2/MD3, encore sans cotes).

Le cap $\lambda=4.0$ reste néanmoins une source de biais sur les
matchs hors-CDM qu'il faudrait isoler en backtest.

5. Detail matchs (page 1)

Match	ΔElo	Pin 1/X/2	V0 1/X/2	V5 1/X/2	Δ p_fav (V5-V0)
FRA-IRQ	+555	84/12/5	85/10/5	89/7/4	+4.07
POR-COD	+412	75/16/9	75/16/9	79/13/8	+3.98
ECU-CUW	+400	76/16/8	74/17/9	78/13/9	+3.97
IRQ-NOR	-388	10/15/74	10/17/73	9/14/77	+3.96
POR-UZB	+383	77/15/8	72/18/10	76/14/9	+3.95
ENG-GHA	+383	71/18/11	72/18/10	76/14/9	+3.95
QAT-SUI	-377	11/17/73	10/16/73	10/15/76	+2.45
COL-COD	+326	64/23/13	69/19/13	71/17/12	+2.45
ARG-ALG	+312	67/22/12	67/19/13	70/18/13	+2.45
MEX-RSA	+309	64/22/14	67/19/13	70/18/13	+2.45
UZB-COL	-297	12/22/66	14/20/66	13/18/68	+2.45
PAN-CRO	-297	14/25/60	14/20/66	13/18/68	+2.45
URU-CPV	+293	67/21/12	66/20/14	68/18/14	+2.45
HAI-SCO	-280	15/19/66	15/21/64	14/19/67	+2.45
FRA-SEN	+267	66/21/13	63/21/16	66/19/15	+2.45
CAN-QAT	+263	63/22/15	63/21/16	65/19/15	+2.45
KSA-URU	-262	16/22/62	16/21/63	15/20/65	+2.45
NED-SWE	+233	58/23/19	60/22/18	62/20/17	+2.45
TUN-JPN	-231	20/28/52	18/22/60	17/20/62	+2.45
BEL-IRN	+226	67/21/13	59/22/18	62/21/18	+2.45
BRA-MAR	+223	58/25/17	59/22/18	61/21/18	+2.45
BEL-EGY	+221	57/24/19	59/22/19	61/21/18	+2.45
AUS-TUR	-215	21/25/53	19/23/58	18/21/61	+2.45
GER-CIV	+198	60/22/18	55/26/20	55/26/20	+0.00
JOR-ALG	-194	20/25/55	20/26/55	20/26/55	+0.00
CZE-RSA	+155	48/29/23	51/26/23	51/26/23	+0.00
NZL-EGY	-146	21/25/55	24/26/50	24/26/50	+0.00
TUR-PAR	+145	42/30/28	50/26/24	50/26/24	+0.00

5. Detail matchs (page 2)

Match	Δ Elo	Pin 1/X/2	V0 1/X/2	V5 1/X/2	Δ p_fav (V5-V0)
IRN-NZL	+141	51/27/23	50/26/24	50/26/24	+0.00
CIV-ECU	-138	25/34/40	24/26/50	24/26/50	+0.00
USA-AUS	+134	54/24/22	49/26/24	49/26/24	+0.00
MEX-KOR	+131	53/26/20	49/26/25	49/26/25	+0.00
NED-JPN	+112	47/26/27	47/27/26	47/27/26	+0.00
SWE-TUN	+110	50/27/23	47/26/27	47/26/27	+0.00
NOR-SEN	+100	47/26/26	46/27/27	46/27/27	+0.00
ENG-CRO	+90	54/25/21	44/28/28	44/28/28	+0.00
SCO-MAR	-73	26/30/45	29/28/43	29/28/43	+0.00
USA-PAR	+64	48/27/26	42/28/30	42/28/30	+0.00
KOR-CZE	+23	36/30/34	38/28/34	38/28/34	+0.00
GHA-PAN	+4	50/25/26	36/28/35	36/28/35	+0.00

6. Recommandation finale et plan de bascule

Resultat sur l'echantillon CDM2026 :

V5 (flip fav_boost + abaisser seuil 200) reduit le bias absolu de -0.80 pts, la MAE de -0.88 pts, et le log-loss de -0.0020.

Si ces ecarts sont >0 et statistiquement non triviaux (>0.5 pp), V5 est candidat naturel a la bascule shadow.

Sequence de bascule recommandee :

1. Etendre l'echantillon : backtest sur 200+ matchs hors-CDM (PL/Liga/Bundesliga/Ligue 1 saisons 24/25 + 25/26) avec resultats reels observes (log-loss vs one-hot, pas vs Pinnacle).
2. Si V5 confirme : creer feature flag SIGMOID_VARIANT en prod.
Valeurs possibles : v8_prod, v8_fixed_v5, v6_pure.
3. Shadow 2 semaines : log les 2 sorties, ne change rien.
4. Blend 70/30 (prod/v5) une semaine.
5. Bascule 100% v5 si KPI stable ou meilleur.
6. Code mort retire apres 30 jours en fallback.

Mises en garde :

- * Pinnacle CDM mid-mai = peu liquide vs ligues de club -> bias d'echantillonnage possible. Backtester sur cotes club closes.
- * Le cap $\lambda=4.0$ ne touche pas la sigmoid 1X2 directement, mais il affecte les buts, donc les depatages buts marques en poule et les buteurs. Le passer a 5.5 demande une analyse separee.
- * La compression Elo amont (blend pin_calibrated + forced) n'est pas etudiee ici : elle est en amont de la sigmoid. Si V5 reste biaise apres bascule, il faudra investiguer pin_weight.